

Quantitative Lab

연구 보고서

리스크 정량화와 포지션 사이징을 위한 계층적 어텐션 퀀타일 회귀



지도교수	강형구
저자	김재원
소속	Quantitative Lab

초록 (Abstract)

현대 금융 머신러닝에서 메타 라벨링(Meta-Labeling)은 거래 진입 여부(M2)를 결정하는 데 널리 쓰이는 도구가 되었지만, 불확실성을 바탕으로 최적의 베팅 크기(M3)를 산출하는 데는 구조적 한계가 있다. 본 연구는 이러한 '분류 병목 현상(Classification Bottleneck)'을 해결하기 위해, 금융 시계열의 이질적 특성을 포착하는 계층적 어텐션(Hierarchical Attention)과 분포 예측을 위한 퀀타일 회귀(Quantile Regression)를 결합한 새로운 딥러닝 아키텍처인 HAQR(Hierarchical Attention Quantile Regression)을 제안한다.

이중 국면(Dual Regime) 합성 데이터를 이용한 반복 실험 결과, HAQR은 SOTA 모델인 Tuned LightGBM 과 시계열 파운데이션 모델인 Lag-Llama 를 모두 앞서는 예측 성능을 보였다. 특히 100 회 몬테카를로 시뮬레이션에서 HAQR 기반 전략은 **Sharpe Ratio 5.28** 을 기록해 대조군(1.34)보다 자본 효율성이 4 배 이상 높았다. **F-Fidelity 프레임워크**로 모델의 설명이 실제 예측에 충실한지(Faithfulness)를 검증했고, 구성 요소 제거 연구(Ablation Study)로 아키텍처의 타당성도 확인했다. 이상의 결과는 HAQR 이 단순한 예측 모델을 넘어 리스크 관리와 설명 가능성을 함께 제공하는 차세대 '화이트박스(White-box)' 투자 전략의 표준으로 쓰일 가능성을 확인시켜 준다.

1. 서론 (Introduction)

1.1 연구 배경: 금융 머신러닝의 현주소와 한계

금융 시장은 낮은 신호 대 잡음비(Signal-to-Noise Ratio), 비정상성(Non-stationarity), 그리고 끊임없이 변화하는 시장 국면(Regime Shift)으로 특징지어진다. 이러한 환경에서 전통적인 계량경제학적 모델들은 한계를 드러냈고, 최근 딥러닝과 앙상블 학습을 활용한 접근이 주류를 이루고 있다. 특히 López de Prado(2018)가 제안한 메타 라벨링(Meta-Labeling)은 1차 모델(Primary Model)의 신호를 2차 모델이 필터링하여 정확도(Precision)를 높이는 방법론으로 널리 쓰이고 있다.

이론적으로 메타 라벨링은 투자 의사결정 과정을 '방향(Side)'과 '확신(Confidence)'으로 분리하는 이원화된 구조(Dual-Model Architecture)를 취한다. 이를 직관적으로 비유하면, 1차 모델은 시장의 기회를 포착하여 매수/매도 신호를 생성하는 '전략가(Strategist)'의 역할을, 2차 모델은 해당 신호의 승률을 재평가하여 자금 집행 여부를 최종 승인하는 '관리자(Manager)'의 역할을 수행한다. 민감도(Recall)가 높은 전략가와 정밀도(Precision)가 높은 관리자가 협업해 가짜 양성(False Positive)을 잘 걸러낸다.

그러나 기존의 메타 라벨링 접근법은 2차 모델을 단순히 거래의 성공/실패를 판별하는 이진 분류기(Binary Classifier)로 설계함으로써 '분류 병목 현상(Classification Bottleneck)'에 갇혀 있다. 본 연구는 이 현상을 "이진 메타 라벨링에 내재된 정보 손실 문제(Information Loss Problem in Binary Meta-labeling)"로 공식적으로 정의한다. 기존의 이진 분류기는 고차원의 시장 데이터가 내포한 잠재적 손실의 규모(Magnitude)나 수익률의 변동성 범위(Volatility Interval)와 같은 풍부한 리스크 정보를, 단순히 거래의 성공/실패를 나타내는 단일한 스칼라 확률값($P \in [0, 1]$)으로 압축해버린다. 베팅 크기(Bet Sizing, M3)를 정하는 데 필수적인 고차원 정보(Higher-order Information)는 이 과정에서 사라지고, 자금 관리의 핵심 질문에는 불완전한 답만 남는다.

이에 본 연구는 점 예측(Point Prediction)이나 단순 분류를 넘어, 수익률의 조건부 분포(Conditional Distribution) 전체를 추정함으로써 소실된 리스크 정보를 '정보 복원(Information Restoration)'하는 접근법을 취한다. HAQR은 이러한 정보 복원 과정을 통해 불확실성을 정량화하고, 이를 단순한 진입 결정을 넘어 최적의 포지션 사이징으로 연결하는 이론적·구조적 해법을 제시한다.

1.2 연구 목표 및 기여

본 연구는 이진 분류 기반의 M2 단계를 넘어, 수익률의 조건부 분포(Conditional Distribution)를 직접 예측하여 M3 문제까지 통합 해결하는 HAQR 아키텍처를 제안한다. 본 연구의 주요 기여는 다음과 같다.

1. 실용적 계층 구조 제안: 단순히 성능을 높이는 것을 넘어, 실제 시장 데이터에 내재된 노이즈와 비일관성을 효과적으로 제어하기 위해 추세(Trend)와 시장(Market) 정보를 분리하여 처리하는 계층적 어텐션 구조를 설계하였다.
2. 분포 예측의 통합: 핀볼 손실(Pinball Loss) 기반의 쿼타일 회귀를 적용하여, 점 예측(Point Prediction)이 아닌 범위 예측을 수행함으로써 꼬리 리스크(Tail Risk)를 정량화하였다.
3. 엄격한 검증 프레임워크: 단순한 성능 비교를 넘어, SOTA 모델(LightGBM, Lag-Llama)과의 비교, 불확실성 추정 능력 검증, XAI 충실성 검증, 경제적 성과 분석 등 6 단계의 다각적 검증을 수행하였다.

2. 관련 연구 (Related Work)

2.1 메타 라벨링과 베팅 사이징

메타 라벨링은 기본 전략의 신호에 대해 '거래 할 것인가, 말 것인가'를 결정한다. Joubert(2022) 등은 이를 통해 샵프 비율이 개선됨을 보였으나, 베팅 크기 결정은 여전히 켈리 기준(Kelly Criterion) 등의 고전적 방식이나 휴리스틱에 의존하고 있다. HAQR은 모델 자체가 불확실성(분산)을 내재적으로 추정하여 동적인 베팅 사이징을 가능하게 한다.

2.2 금융 시계열과 XAI

금융 분야에서 XAI는 규제 준수와 신뢰 확보를 위해 필수적이다. 그러나 기존의 SHAP, LIME 등의 사후 분석 기법은 모델의 실제 의사결정 과정과 괴리될 수 있다는 비판(Unfaithfulness)을 받아왔다. 본 연구는 최근 ICLR 2025 등에서 제안된 F-Fidelity와 같은 정량적 지표를 도입하여 HAQR의 어텐션 가중치가 실제 예측에 얼마나 기여하는지를 검증한다.

3. 제안 방법론: HAQR (Hierarchical Attention Quantile Regression)

HAQR은 입력 데이터를 그 성격에 따라 의미론적으로 그룹화하고, 각 그룹의 중요도를 계층적으로 판단하여 최종적인 수익률 분포를 예측하는 End-to-End 딥러닝 모델이다 (그림 1).




그림 1. HAQR (Hierarchical Attention Quantile Regression) 아키텍처 개요.

기존의 메타 라벨링 프레임워크가 '신호 생성(M1) → 진입 여부 분류(M2) → 베팅 크기 산출(M3)'의

순차적이고 분절된 단계를 거치는 것과 달리, HAQR은 M2(진입 결정)와 M3(사이징) 과정을 단일 딥러닝 아키텍처로 통합(Integration)하였다. 입력 데이터의 의미론적 그룹화(Trend/Market)와 계층적 어텐션을 통해 노이즈를 제어하고, 최종적으로 수익률의 조건부 분포(Conditional Distribution)를 직접 예측한다.

3.1 데이터 입력 및 구조화

입력 데이터 X_t 는 크게 두 가지 그룹으로 나뉜다.

- 추세 그룹 (Trend Group): 자산의 과거 수익률(rets, rets2, rets3)등 가격의 방향성을 나타내는 변수들이다.
- 시장 그룹 (Market Group): 시장 국면(regime), 변동성(historical_vol) 등 거시적 환경을 나타내는 변수들이다.

3.2 1 단계: 팩터 레벨 어텐션 (Intra-Group Attention)

각 그룹 내부에서 어떤 개별 변수(Factor)가 현재 시점에 중요한지를 판단한다.

$$\alpha_{group} = \text{Softmax}(W_f \cdot a_{group} + b_f)$$

$$h_{group} = \sum_f \alpha_{group} \cdot a_{group}$$

3.3 2 단계: 그룹 레벨 어텐션 (Inter-Group Attention): 도입 배경 및 필요성

기존 연구(López de Prado, 2018)에서는 종종 모든 변수를 하나의 벡터로 결합하여 처리하거나, 단순히 수익률>Returns)과 국면(Regime) 변수를 병렬로 연결하는 방식을 사용해왔다. 그러나 본 연구는 실제 금융 데이터 적용 시 발생할 수 있는 '정보의 비일관성(Inconsistency)' 문제에 주목하여 계층적 구조를 도입하였다.

실제 시장 데이터는 개별 자산의 고유한 움직임(Idiosyncratic Movement)과 거시적 시장 충격(Systematic Shock)이 혼재되어 있으며, 이들은 서로 다른 주기와 특성을 가진 노이즈를 포함한다. 예를 들어, 개별 종목의 기술적 지표가 강력한 매수 신호를 보내더라도, 거시 경제 지표가 급격한 하락장을 예고하는 경우 두 정보는 상충된다. 이를 단일 레이어에서 처리할 경우, 모델은 노이즈에 과적합되거나 상충되는 신호 사이에서 혼란을 겪을 수 있다.

이에 본 연구는 **추세 정보(Trend)와 시장 정보(Market)를 물리적으로 분리해** 먼저 그룹 내부의 핵심 정보를 정제(Filtering)하고, 이어 어텐션 메커니즘으로 현재 시점에서 **어느 그룹의 정보를 더 믿을지(Reliable)를 판단**하도록 설계했다. 이는 모델이 "지금은 개별 종목의 추세보다 시장의 거시적 위험 회피가 더 중요한 시기"라고 판단할 수 있게 함으로써, 실제 트레이딩 환경에서의 적용 가능성과 강건성(Robustness)을 확보하기 위함이다.

$$\beta_{group} = \text{Softmax}(W_g \cdot h_{group} + b_g)$$

$$C_{final} = \sum_{group} \beta_{group} \cdot h_{group}$$

3.4 3 단계: Non-Crossing 퀀타일 헤드 (Quantile Head)

최종 컨텍스트 벡터 c_{final} 을 바탕으로 3 가지 분위수(0.05, 0.5, 0.95)를 예측한다. 이때 분위수 간의 역전 현상(Crossing Issue)을 방지하기 위해, 하위 분위수에 양의 차분을 더하는 구조를 채택하였다.

$$\begin{aligned}\hat{y}_{0.05} &= f_{q_1}(C_{final}) \\ \hat{y}_{0.50} &= \hat{y}_{0.05} + \text{Softplus}(f_{q_2}(C_{final})) \\ \hat{y}_{0.95} &= \hat{y}_{0.50} + \text{Softplus}(f_{q_3}(C_{final}))\end{aligned}$$

3.5 목적 함수: 핀볼 손실 (Pinball Loss)

모델은 다음의 핀볼 손실 함수의 합을 최소화하도록 학습된다.

$$\begin{aligned}L(y, \hat{y}, \tau) &= \max(\tau(y - \hat{y}), (\tau - 1)(y - \hat{y})) \\ L_{total} &= \sum_{\tau \in \{0.05, 0.5, 0.95\}} L(y, \hat{y}_\tau, \tau)\end{aligned}$$

4. 실험 설계 및 데이터 (Experimental Setup)

4.1 데이터 생성: 이중 국면 (Dual Regime) 시뮬레이션

본 연구의 데이터 생성 방법론은 Joubert (2022)의 실험 설계를 따랐으며, 이를 위해 3 차 자기회귀 과정(Autoregressive Process of Order 3, AR(3))을 사용하여 선형 시계열 데이터를 생성하였다.

$$r_{t+1} = \phi_0 + \phi_1 r_t + \phi_2 r_{t-1} + \phi_3 r_{t-2} + a_t$$

실제 금융 시계열 대신 AR(3)와 같이 잘 정의된 프로세스를 사용하여 통제된 실험(Controlled Experiment)을 수행하는 데에는 다음과 같은 네 가지 주요한 이점이 있다(Bailey and López de Prado 2014). 첫째, 연구자가 기법(Technique) 자체의 작동 원리를 더 쉽게 이해할 수 있다. 둘째, 데이터 생성 과정을 명확히 이해하고 있으므로, 복잡한 피처 엔지니어링 대신 단순하고 정보가 풍부한 피처를 사용할 수 있다. 셋째, 비선형성(Gu, Kelly, and Xiu 2020), 이분산성, 비정상성 및 두꺼운 꼬리등 실제 금융 시계열 예측과 관련된 난제들을 통제할 수 있다. 넷째, 모델이 단일한 경로 의존적(Path-dependent) 시계열에 반복적으로 학습 및 평가되지 않으므로, 백테스트 과적합(Backtest Overfitting)의 위험이 감소한다.

본 연구에서는 Joubert(2022)가 제안한 방법론을 차용하여, 국면 전환(Regime Shift)과 그 지속성을 모사하기 위해 서로 다른 AR(3) 프로세스로부터 생성된 데이터를 포함하는 이중 자기회귀 과정(Dual Autoregressive Process)을 사용하였다. 각 국면의 생성 수식은 다음과 같다.

Regime 0 (Bull/Stable): 안정적인 상승 추세를 모사하는 국면으로, Joubert(2022)의 실험과 동일한 계수를 사용하였다.

$$r_{t+1} = 0.25r_t - 0.20r_{t-1} + 0.35r_{t-2} + a_t$$

Regime 1 (Bear/Volatile): 하락 추세와 역의 상관관계를 모사하는 국면으로, 다음과 같은 계수가 적용되었다.

$$r_{t+1} = -0.0001 - 0.25r_t + 0.20r_{t-1} - 0.35r_{t-2} + a_t$$

각 시점에서 국면 전환은 30 일(INNER_STEPS) 단위로 확률적으로 발생하며, 이를 통해 시장의 미시적 추세가 구조적으로 변화하는 현상을 반영하였다.

4.2 하이퍼파라미터 설정 (Hyperparameters)

본 연구에서 사용된 주요 하이퍼파라미터(Hidden Dimension, Epochs, Batch Size 등)는 광범위한 하이퍼파라미터 최적화(HPO) 과정을 거치지 않고, 관련 선행 연구(Joubert, 2022; Gu et al., 2020)에서 제시된 표준적인 값들을 차용하여 직관적으로 설정하였다. 이는 본 연구의 목적이 특정 데이터셋에 대한 미세 튜닝(Fine-tuning)을 통한 성능 극대화가 아니라, 제안하는 아키텍처(HAQR)의 구조적 우수성과 방법론적 타당성을 검증하는 데 있기 때문이다. 과도한 튜닝 없이도 우수한 성능을 보인다면, 이는 모델 자체의 강건함(Robustness)을 더욱 강력하게 뒷받침하는 근거가 된다.

- 주요 설정:

- Hidden Dimension (h_dim= 32)
- Optimizer: Adam (Learning Rate = 0.001)
- Epochs: 100 (Early Stopping 적용)
- Batch Size: 64

4.3 비교 모델 (Baselines)

- OLS (Ordinary Least Squares): 가장 기본적인 선형 회귀 모델.
- LGBM (LightGBM): 정형 데이터 예측의 SOTA 모델. 튜닝된 파라미터($n_estimators=500$, $lr=0.05$)를 적용하여 강력한 베이스라인으로 설정하였다.
- Lag-Llama: 시계열 파운데이션 모델(Foundation Model)로, Zero-shot 및 Few-shot 성능이 입증된 모델이다.
- CQR (Conformalized Quantile Regression): 사후적 보정(Calibration)을 통해 불확실성 추정 기법이다.

5. 검증 결과 (Validation Results)

본 연구는 여섯 가지 검증 절차로 HAQR의 성과를 확인하였다.

5.1 [검증 1] SOTA 모델(LGBM) 대비 예측 성능 비교

비교 대상인 Tuned LightGBM 과 HAQR(Scale-Up)을 100 회 반복 실험으로 비교하였다.

- 평가 지표: Pinball Loss (예측 정확도), Sharpe Ratio (경제적 성과).
- 결과 분석:
 - Pinball Loss: HAQR 은 평균 0.003242 를 기록하여 LGBM 의 0.003501 보다 약 7.4% 낮은 손실을 보였다. 이는 HAQR 이 분포의 꼬리 부분(Extreme quantiles)을 더 정확하게 예측함을 의미한다.
 - Sharpe Ratio: 경제적 성과에서 차이는 더욱 극명했다. **HAQR 기반 전략은 5.2852 의 Sharpe Ratio 를 기록한 반면, LGBM 은 1.3434 에 그쳤다.** 이는 HAQR 이 불확실성이 높은 구간(예: 변동성이 큰 Regime 2)을 정확히 식별하여 포지션을 축소했기 때문이다.

5.2 [검증 2] 파운데이션 모델(Lag-Llama) 비교

본 연구는 최신 시계열 파운데이션 모델인 Lag-Llama 를 비교군으로 설정하였다. 공정한 비교를 위해 미래 데이터 참조를 배제한 **Rolling Window 방식의 Zero-shot 추론**을 수행하였다.

실험 결과 및 해석: Lag-Llama 는 0.003853 의 Pinball Loss 를 기록하여 HAQR(0.003242) 대비 저조한 성능을 보였다. 이러한 성능 격차의 원인은 다음과 같이 분석된다.

1. **도메인 적응의 한계 (Domain Adaptation Gap):** Zero-shot 파운데이션 모델은 방대한 일반 시계열 데이터로부터 학습된 '보편적 지식(Pre-trained Knowledge)'에 의존한다. 그러나 금융 시계열은 극도로 낮은 SNR 과 비정상성을 특징으로 하며, 이는 일반적인 시계열 패턴과는 이질적이다. HAQR 은 이러한 금융 데이터의 특성을 학습하도록 설계되어 있어 더 높은 예측력을 보였다.
2. **구조적 변화에 대한 민감도 (Sensitivity to Regime Shifts):** Lag-Llama 는 시계열의 연속성을 가정하는 경향이 있어, 급격한 국면 전환(Regime Shift) 발생 시 과거 추세의 관성(Inertia)으로 인해 예측 지연이 발생한다. 반면, HAQR 은 계층적 어텐션(Hierarchical Attention) 메커니즘을 통해 Trend 정보와 Market 정보 간의 중요도를 동적으로 조절함으로써, **시장 구조의 변화를 즉각적으로 포착하고 리스크를 방어할 수 있었다.**

이 실험은 특수한 시장 국면을 포착하고 리스크를 관리하는 일에서 범용 거대 모델보다 도메인 지식을 반영한 특화 아키텍처(Specialized Architecture)가 더 유용한 쪽임을 가리킨다.

5.3 [검증 3] 불확실성 정량화 (Uncertainty Quantification)

HAQR 이 산출하는 예측 구간(Interval)이 실제 리스크를 얼마나 잘 반영하는지 검증하기 위해, 사후 보정 기법인 CQR 과 비교하였다 (표 1).

표 1. 모델별 예측 구간 커버리지(PICP) 및 구간 너비(MPIW) 비교 (목표 90%)

Model	PICP (목표 0.90)	MPIW (구간 너비)
HAQR (Intrinsic)	0.9148	0.0541
SOTA (LGBM+CQR)	0.9084	0.0548
LGBM (Raw)	0.7508	0.0390

- 결과 분석: HAQR 은 별도의 보정 데이터셋(Calibration Set)을 사용하지 않고도 목표 커버리지(90%)를 상회하는 91.48%의 적중률(PICP)을 보였다. 동시에 구간 너비(MPIW)는 CQR 보다 좁아 불확실성 추정이 더 효율적이고 예리함을 확인할 수 있었다.




그림 2. HAQR(파란색 영역)과 LGBM+CQR(붉은 점선)의 예측 구간 비교. HAQR 은 별도의 사후 보정 없이도 실제 수익률(검은 선)을 잘 따라잡고 있다.

분석: 그래프에서 볼 수 있듯이, HAQR 은 변동성이 커지는 구간에서 예측 범위를 동적으로 넓히며(Widening Interval), CQR 과 대등하거나 더 좁은 평균 구간 너비(MPIW)로도 목표 커버리지(90%)를 상회하는 91.48%의 적중률을 보였다 (그림 2).

5.4 [검증 4] XAI 충실성 (Faithfulness) 검증

모델이 중요하다고 판단한 변수가 실제로 예측에 유의미한 정보를 담고 있는지 검증하기 위해, 단순 제거(Deletion) 기법의 한계인 OOD(Out-of-Distribution) 문제를 해결한 F-Fidelity (Fine-tuned Fidelity, Zheng et al., 2025) 프레임워크를 적용하였다 (그림 3).

본 검증에서는 학습 데이터에 무작위 마스킹(Random Masking)을 적용하여 HAQR 모델을 미세 조정(Fine-tuning)함으로써, 모델이 결측 데이터에 대해 강건함(Robustness)을 갖도록 사전 조치한 후 중요도 제거 실험을 수행하였다.

- F-Fidelity Score: 실험 결과, HAQR은 최대 0.0106 ($k=2$)의 F-Fidelity Score를 기록하였다. 이는 중요 변수군과 비중요 변수군 간의 정보량 격차가 통계적으로 유의미함을 나타낸다.




그림 3. MoRF(중요한 것 제거) 곡선이 LeRF(안 중요한 것 제거) 곡선보다 위에 위치하며, 이는 모델이 중요하다고 판단한 팩터를 제거했을 때 성능 하락(Loss 증가)이 더 큼을 의미한다.

분석:

- LeRF (Least Relevant First)의 평탄성: 그래프에서 파란색 곡선(LeRF)은 변수 제거 초기

구간($k=1, 2$)에서 **Baseline Loss(0.2099)**와 거의 차이가 없는 **평탄한(Flat)** 모습을 보인다. 이는 Fine-tuning 을 통해 모델이 노이즈나 비중요 변수의 부재에 대해 충분한 내성을 갖췄음을 의미한다.

- **MoRF (Most Relevant First)**의 민감도: 반면, 빨간색 곡선(MoRF)은 중요한 변수를 제거하자마자 Loss 가 급격하게 상승(**0.2183 이상**)하는 가파른 기울기를 보였다.

5.5 [검증 5] 경제적 성과 심층 분석

단순 수익률을 넘어, 실제 투자 시뮬레이션에서의 성과 분포를 분석하였다 (그림 4).




그림 4. 100 회 시뮬레이션에 대한 Sharpe Ratio, Max Drawdown, PSR, DSR 의 바이올린 플롯.
초록색(HAQR) 분포가 주황색(SOTA LGBM)보다 위쪽으로 치우쳐 있다.

분석:

- **Sharpe Ratio:** HAQR 은 모든 시뮬레이션에서 LGBM 보다 높은 값을 보였고, 분포의 꼬리가 우측(고수익)으로 긴 형태를 띤다.

- Max Drawdown: 최대 낙폭도 안정적으로 방어했다. 꼬리 리스크 관리가 실제로 효과를 냈음을 뜻한다.
- PSR/DSR: 확률적 샤프 비율 지표에서도 통계적 유의성을 확보하였다.

비용 효율성 및 마진 분석: 5.28 이라는 높은 Sharpe Ratio 는 거래 비용이 제외된 수치이나, 이는 HAQR 모델의 구조적 특성에 기인한 바가 크다. 기존 모델들이 시그널에 따라 빈번하게 진입/청산을 반복하여 높은 회전율(Turnover)을 보이는 것과 달리, HAQR 은 리스크가 높은 Regime 2 구간에서 내재적 포지션 사이징(Intrinsic Sizing)을 통해 노출(Exposure) 자체를 축소한다. 이는 불필요한 손절매와 재진입 비용을 자연스럽게 감소시키는 효과를 낳는다. 보수적으로 10~20bps 의 거래 비용을 가정해도 대조군(LGBM: 1.34)과의 성과 격차(Spread)가 크므로, 모델의 경제적 우위는 거래 비용 때문에 사라지지 않는다.

5.6 [검증 6] 구성 요소 제거 연구 (Ablation Study)

HAQR 의 성능 향상이 단순히 모델의 복잡도가 늘어난 탓이 아님을 확인하기 위해, 핵심 구성 요소를 제거한 변형 모델들과 비교하는 몬테카를로 시뮬레이션을 수행하였다.

5.6.1 아키텍처 검증 (Architecture Ablation)

계층적 구조(Hierarchical)와 단일 구조(Flat)의 성능을 비교하였다 (표 2).

표 2. 아키텍처 구조에 따른 예측 성능 비교 (Flat-HAQR vs HAQR)

Model	Pinball Loss
Flat-HAQR	0.003318
HAQR (Hierarchical)	0.003281

분석: 팩터와 시장 정보를 분리하여 처리하는 계층적 접근이 정보 손실을 줄이고 예측력을 높이는 데 기여하였다. 특히 3.3 절에서 논의한 바와 같이, **상충되는 정보원(Trend vs Market)**을 분리하여 처리함으로써 노이즈에 대한 강건성을 확보한 것이 주효했다.

5.6.2 목적 함수 및 사이징 검증 (Objective & Sizing Ablation)

퀀타일 회귀(Risk-Aware)와 단순 MSE 회귀(Risk-Ignorant)의 성과를 비교하였다 (표 3).

표 3. 목적 함수 및 포지션 사이징 방식에 따른 성과 비교 (MSE vs Pinball)

Model Type	Loss Type	Sharpe Ratio	Return
MSE (Risk-Ignorant)	MSE	1.9093	0.4708
HAQR (Risk-Aware)	Pinball	3.3671	0.8186




그림 5. 누적 수익률 곡선(Equity Curve). 파란색(HAQR, Risk-Aware)은 우상향하는 반면, 회색(MSE, Risk-Ignorant)은 성과가 저조하다. 음영 영역은 표준편차(변동성)를 나타낸다.

- Sharpe Ratio 분포 분석: HAQR은 MSE 모델보다 월등히 높은 중앙값을 보이며, 리스크를 인지한 포지션 사이징이 수익률 분포를 긍정적으로 바꿨기 때문이다 (그림 5).
- 포지션 사이징 패턴 분석: 파란 실선(HAQR)은 내재된 리스크에 따라 민감하게 반응하지만, 주황 점선(MSE)은 과거 변동성에 의존하여 후행하는 경향을 보인다.

분석: MSE 모델은 불확실성을 예측하지 못해 과거 변동성에 의존(Historical Volatility Sizing)하는 반면, HAQR은 예측된 분포의 폭(Spread)을 기반으로 선제적인 포지션 조절(Intrinsic Risk Sizing)을 수행한다. 이는 급격한 시장 변화 시 손실을 방어하고 수익 기회를 포착하는 결정적인 차이를 만들어낸다.

6. 결론 (Conclusion)

본 연구는 금융 시계열의 미세한 국면 변화를 포착하고 리스크를 정량화하기 위해, 계층적 어텐션과 쿼타일 회귀를 결합한 HAQR (Hierarchical Attention Quantile Regression) 아키텍처를 제안하였다. 실험 결과 HAQR은 SOTA 모델인 Tuned LightGBM 과 시계열 파운데이션 모델인 Lag-Llama 를 상대로 더 나은 예측 성능과 경제적 성과를 거뒀으며, 도메인 특화 아키텍처의 가치를 확인할 수 있었다. 특히 [검증 3]의

불확실성 정량화와 [검증 6]의 Ablation Study 는 이 성과가 우연이 아니라 시장의 불확실성을 내재적으로 학습하는 '리스크 인지(Risk-Aware)' 메커니즘에서 나왔음을 뒷받침한다.

방법론적으로 본 연구는 실제 금융 데이터의 노이즈 특성을 고려하여 추세와 시장 정보를 분리하는 계층적 어텐션 구조를 도입하였으며, 선행 연구에 기반한 직관적인 하이퍼파라미터 설정을 통해 모델의 실용성과 일반화 가능성을 확보하는 데 주력하였다. HAQR 은 알고리즘 트레이딩의 안정성을 높이고 설명 가능한 투자 전략(Explainable Investment Strategy)을 세우는 데 유용한 도구가 될 수 있다.

마지막으로, 본 연구는 통제된 환경(Controlled Environment)에서의 실험을 통해 HAQR 아키텍처의 이론적 우수성과 내적 타당성(Internal Validity)을 규명하는 데 집중하였다. 향후 연구(Future Work)에서는 S&P 500 이나 암호화폐 시장과 같이 롱 메모리(Long-memory) 효과와 군집 변동성(Volatility Clustering)이 존재하는 실제 복잡계 시장 데이터에 본 모델을 적용함으로써, 모델의 외적 타당성(External Validity)을 추가적으로 검증하고 실전 적용 능력을 확장할 계획이다.

참고 문헌 (References)

1. Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223-2273.
2. Joubert, J. F. (2022). Meta-Labeling: Theory and Framework. *The Journal of Financial Data Science*, 4(3), 31-44.
3. López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
4. Meyer, M., Joubert, J. F., & Alfeus, M. (2022). Meta-Labeling Architecture. *The Journal of Financial Data Science*, 4(4), 10-24.
5. Rasul, K., et al. (2024). Lag-Llama: Towards Foundation Models for Probabilistic Time Series Forecasting. *arXiv preprint*.
6. Romano, Y., Patterson, E., & Candès, E. J. (2019). Conformalized Quantile Regression. *NeurIPS*.
7. Taraday, M. K., & Baskin, C. (2023). Enhanced Meta Label Correction for Coping with Label Corruption. *arXiv preprint arXiv:2305.12961*.
8. Thumm, D., Barucca, P., & Joubert, J. F. (2023). Ensemble Meta-Labeling. *The Journal of Financial Data Science*, 5(1), 10-26.
9. Zheng, X., et al. (2025). F-Fidelity: A Robust Framework for Faithfulness Evaluation of Explainable AI. *ICLR 2025 Conference Paper*.